

BEEIA: Análise de Ameaças em Sistemas Ciber-Físicos usando Honeypots e IA.

Autores: Caio S. G. Souza | caio.silveira@iesb.edu.br
Mayron M.Oliveira | mayron.oliveira@iesb.edu.br
Pablo Coelho Ferreira | pablo.ferreira@iesb.edu.br

OBJETIVO

Este trabalho tem como objetivo desenvolver um sistema inteligente de monitoramento de ameaças cibernéticas, baseado em Honeypots, capaz de capturar e classificar automaticamente tentativas de invasão por meio de algoritmos de Machine Learning. O sistema também integra um Modelo de Linguagem de Grande Escala (LLM) para interpretar os dados coletados e gerar relatórios analíticos em linguagem natural, oferecendo suporte à tomada de decisão em tempo real. Os objetivos secundários são

- Desenvolver uma interface de back-end que utilize uma LLM para traduzir os dados técnicos classificados em insights estratégicos e resumos em linguagem natural.
- Implementar uma armadilha de rede em ambiente controlado para a captação de logs brutos provenientes de tentativas de invasão e varreduras maliciosas.
- Treinar e validar algoritmos de classificação (como Random Forest, SVM ou XGBoost) para categorizar os ataques detectados por nível de criticidade e tipo de exploração.
- Criar uma interface gráfica interativa para a visualização de gráficos, mapas de calor de ataques e métricas de desempenho da rede monitorada (representação na Figura 1)




Figura 1: Interface principal do Dashboard de Monitoramento.

METODOLOGIA

Foi definida uma arquitetura metodológica para o monitoramento inteligente de ameaças cibernéticas em tempo real. O processo foi estruturado na Figura 2 em um pipeline composto por:




Figura 2: Diagrama de sequência: conexão SSH/Telnet → classificação → bloqueio automático via iptables

- Captura de tráfego malicioso via Honeypot Cowrie/Dionaea em container Docker isolado;
- Deteção de encerramento de sessão e extração de logs brutos pelo módulo log_watcher;
- Pré-processamento e normalização dos eventos para geração de 13 características numéricas;
- Classificação automatizada das ameaças por nível de criticidade e tipo de exploração com Random Forest;
- Persistência dos ataques classificados com dados geográficos em banco SQLite via FastAPI;
- Interpretação dos dados técnicos e geração de relatórios em linguagem natural por meio de LLM;
- Tomada de decisão automatizada com bloqueio de IP via iptables para sessões com confiança acima de 95%.

RESULTADOS E DISCUSSÕES

Os resultados preliminares obtidos com a aplicação da metodologia proposta demonstram a viabilidade

técnica do sistema. Entre as principais conquistas, destacam-se:

- Desempenho de ML: O modelo Random Forest diferenciou com êxito as quatro classes de ataque modeladas — *brute_force*, *recon*, *command_injection* e *malware_download* —, apresentando métricas consistentes de precisão e revocação nos testes realizados.
- Operação em Tempo Real: Validação de ponta a ponta com ferramentas de teste de intrusão (Hydra e Metasploit) com latência de exibição no Dashboard inferior a 2 segundos.

Paralelamente, foram identificadas limitações a serem tratadas nas etapas subsequentes do projeto:

- Dados sintéticos: A calibração inicial do classificador depende parcialmente de dados sintéticos, o que pode introduzir viés em cenários com padrões de ataque ainda não observados em ambiente real.
- Geolocalização: A dependência de serviço externo para enriquecimento geográfico dos eventos representa um ponto de falha potencial em ambientes sem conectividade irrestrita.

REFERÊNCIAS



Escaneie para visualizar o compilador de referências e a galeria de arquitetura do sistema.